

基于误差状态卡尔曼滤波的 GPS/IMU 与 VIO 融合导航

金宇强 1112003021

摘要 针对 GPS (Global positioning system) 信号不足或丢失环境下的无人车定位导航问题, 使用误差状态卡尔曼滤波 (ESKF) 分别实现了 GPS/IMU 与 VIO 融合定位。不同于传统的扩展卡尔曼 (EKF) 框架, ESKF 对误差状态进行更新与修正, 由于误差状态是小量, 并且其线性程度较高, 因此其局部线性化的模型误差更小, 可以提高状态估计的精度。通过 Matlab 分别设计了基于 GPS/IMU 和 VIO 定位的仿真场景, 结果验证了基于 ESKF 的融合能有效提高定位精度。

关键词 定位导航; GPS/IMU; VIO; 误差状态卡尔曼滤波

引言

车辆的高精度定位导航是智能驾驶的关键技术之一, 目前, 全球定位系统 (GPS)、惯性导航系统 (INS) 因其易集成、低成本, 成为应用最为广泛的 2 种导航方法。但在室内环境或城市环境中, GPS 和 IMU 都容易受到外部电磁干扰, 且 GPS 信号易丢失, 而常见的视觉传感器测量精度高, 不受电磁信号影响, 且与 IMU 存在天然的互补优势, 因而被广泛集成在车辆导航系统上。本文介绍了基于 ESKF 的融合框架 (松耦合), 首先讨论在低频 GPS 信号场景下, 将高频 IMU 信号与低频 GPS 信号进行融合, 提高定位精度。然后引入了视觉里程计的漂移模型, 并讨论在无 GPS 信号情况下, 将 VO 测量的位姿与 IMU 信号进行融合, 实现了基于 VIO 的定位导航。通过 Matlab 的仿真场景与代码实现, 验证了该框架的有效性, 具体代码地址可见¹。

1 基于误差状态卡尔曼滤波的 GPS/IMU 融合

1.1 符号定义

为了方便分析, 定义 ESKF 中的所有变量如表 1 所示, 其中 \oplus 表示广义的加法, 另外, Δt 表示时间离散状态的时间间隔, $\mathbf{I} \in \mathbb{R}^3$ 表示单位矩阵, $\mathbf{L}_{sk}(\mathbf{b})$ 表示向量 $\mathbf{b} \in \mathbb{R}^3$ 构成的反对称矩阵, $\mathbf{g} \in \mathbb{R}^3$ 为重力向量, 算子 $q(\theta)$ 和 $R(\theta)$ 分别表示轴角向量 θ 对应的四元数及其旋转矩阵, 本文涉及的四元数乘法、矩阵对数以及李群李代数的指数映射均参考文[1][3]。

¹ <https://github.com/uyuJin/Informationfusion>

表 1 相关符号定义表

名称	真实状态	标称状态	误差状态	运算律	测量	噪声
全状态 $\in \mathbb{R}^{16}$	\mathbf{x}_t	\mathbf{x}	$\delta \mathbf{x}$	$\mathbf{x}_t = \mathbf{x} \oplus \delta \mathbf{x}$		
位置 $\in \mathbb{R}^3$	\mathbf{p}_t	\mathbf{p}	$\delta \mathbf{p}$	$\mathbf{p}_t = \mathbf{p} + \delta \mathbf{p}$		
速度 $\in \mathbb{R}^3$	\mathbf{v}_t	\mathbf{v}	$\delta \mathbf{v}$	$\mathbf{v}_t = \mathbf{v} + \delta \mathbf{v}$		
四元数 $\in \mathbb{R}^3$	\mathbf{q}_t	\mathbf{q}	$\delta \mathbf{q}$	$\mathbf{q}_t = \mathbf{q} \otimes \delta \mathbf{q}$		
旋转矩阵 $\in \text{SO}(3)$	\mathbf{R}_t	\mathbf{R}	$\delta \mathbf{R}$	$\mathbf{R}_t = \mathbf{R} \delta \mathbf{R}$		
轴角 $\in \mathbb{R}^3$				$\delta \mathbf{q} = \mathbf{e}^{\delta \theta / 2}$ $\delta \mathbf{R} = \mathbf{e}^{[\delta \theta]_{\times}}$		
加速度偏置 $\in \mathbb{R}^3$	\mathbf{a}_{bt}	\mathbf{a}_b	$\delta \mathbf{a}_b$	$\mathbf{a}_{bt} = \mathbf{a}_b + \delta \mathbf{a}_b$		\mathbf{a}_w
角速度偏置 $\in \mathbb{R}^3$	$\boldsymbol{\omega}_{bt}$	$\boldsymbol{\omega}_b$	$\delta \boldsymbol{\omega}_b$	$\boldsymbol{\omega}_{bt} = \boldsymbol{\omega}_b + \delta \boldsymbol{\omega}_b$		$\boldsymbol{\omega}_w$
加速度 $\in \mathbb{R}^3$	\mathbf{a}_t				\mathbf{a}_m	\mathbf{a}_n
角速度 $\in \mathbb{R}^3$	$\boldsymbol{\omega}_t$				$\boldsymbol{\omega}_m$	$\boldsymbol{\omega}_n$

1.2 IMU 动力学方程

根据[2][3]，真实状态的连续时间 IMU 动力学方程如下：

$$\begin{aligned}
 \dot{\mathbf{p}}_t &= \mathbf{v}_t \\
 \dot{\mathbf{v}} &= \mathbf{R}_t(\mathbf{a}_m - \mathbf{a}_{bt} - \mathbf{a}_n) + \mathbf{g}_t \\
 \dot{\mathbf{q}}_t &= \frac{1}{2} \mathbf{q}_t \otimes (\boldsymbol{\omega}_m - \boldsymbol{\omega}_{bt} - \boldsymbol{\omega}_n) \\
 \dot{\mathbf{a}}_{bt} &= \mathbf{a}_\omega, \quad \dot{\boldsymbol{\omega}}_{bt} = \boldsymbol{\omega}_\omega
 \end{aligned} \tag{1}$$

其中 \mathbf{a}_n 和 $\boldsymbol{\omega}_n \in \mathbb{R}^3$ 分别表示加速度和角速度测量白噪声， \mathbf{a}_ω 和 $\boldsymbol{\omega}_\omega \in \mathbb{R}^3$ 分别表示加速度和角速度的偏置向量，标称（名义状态）的 IMU 动力学方程如下：

$$\begin{aligned}
 \dot{\mathbf{p}} &= \mathbf{v} \\
 \dot{\mathbf{v}} &= \mathbf{R}(\mathbf{a}_m - \mathbf{a}_b) + \mathbf{g} \\
 \dot{\mathbf{q}} &= \frac{1}{2} \mathbf{q} \otimes (\boldsymbol{\omega}_m - \boldsymbol{\omega}_b) \\
 \dot{\mathbf{a}}_b &= 0, \quad \dot{\boldsymbol{\omega}}_b = 0
 \end{aligned} \tag{2}$$

根据式（1）和（2）即得到误差状态的动力学方程：

$$\begin{aligned}
 \delta \dot{\mathbf{p}} &= \delta \mathbf{v} \\
 \delta \dot{\mathbf{v}} &= \mathbf{R} \mathbf{L}_{sk}(\mathbf{a}_m - \mathbf{a}_b) \delta \theta - \mathbf{R} \delta \mathbf{a}_b - \mathbf{R} \mathbf{a}_n \\
 \delta \dot{\boldsymbol{\theta}} &= -\mathbf{L}_{sk}(\boldsymbol{\omega}_m - \boldsymbol{\omega}_b) \delta \theta - \delta \boldsymbol{\omega}_b - \boldsymbol{\omega}_n \\
 \delta \dot{\mathbf{a}}_b &= \mathbf{a}_\omega \\
 \delta \dot{\boldsymbol{\omega}}_b &= \boldsymbol{\omega}_\omega
 \end{aligned} \tag{3}$$

在实际应用中，上述的微分方程需要转换为差分方程，其中，标称状态

的运动模型递推表达式为:

$$\begin{aligned}
\mathbf{p}_{k+1} &= \mathbf{p}_k + \mathbf{v}_k \Delta t + \frac{1}{2} (\mathbf{R}_k (\mathbf{a}_{mk} - \mathbf{a}_{bk}) + \mathbf{g}) \Delta t^2 \\
\dot{\mathbf{v}} &= \mathbf{v}_k + (\mathbf{R}(\mathbf{a}_m - \mathbf{a}_b) + \mathbf{g}) \Delta t \\
\mathbf{q}_{k+1} &= \mathbf{q}_k \otimes \mathbf{q}_k ((\boldsymbol{\omega}_m - \boldsymbol{\omega}_b) \Delta t) \\
\mathbf{a}_{b(k+1)} &= \mathbf{a}_{bk} \\
\boldsymbol{\omega}_{b(k+1)} &= \boldsymbol{\omega}_{bk}
\end{aligned} \tag{4}$$

其中 k 即表示第 k 时刻, 误差状态的运动模型递推公式为:

$$\begin{aligned}
\delta \mathbf{p}_{k+1} &= \delta \mathbf{p}_k + \delta \mathbf{v}_k \Delta t \\
\delta \mathbf{v}_{k+1} &= \delta \mathbf{v}_k + (-\mathbf{R}_k \mathbf{L}_{sk} (\mathbf{a}_{mk} - \mathbf{a}_{bk}) \delta \boldsymbol{\theta}_k - \mathbf{R} \delta \mathbf{a}_{bk}) \Delta t + \mathbf{w}_{vk} \\
\delta \boldsymbol{\theta}_{k+1} &= \mathbf{R}_k^T ((\boldsymbol{\omega}_{mk} - \boldsymbol{\omega}_{bk}) \Delta t) \delta \boldsymbol{\theta} - \delta \boldsymbol{\omega}_{bk} \Delta t - \mathbf{w}_{\theta k} \\
\delta \mathbf{a}_{b(k+1)} &= \delta \mathbf{a}_{bk} + \mathbf{w}_{ak} \\
\delta \boldsymbol{\omega}_{b(k+1)} &= \delta \boldsymbol{\omega}_{bk} + \mathbf{w}_{\omega k}
\end{aligned} \tag{5}$$

其中 \mathbf{w}_{vk} , $\mathbf{w}_{\theta k}$, \mathbf{w}_{ak} , $\mathbf{w}_{\omega k} \in \mathbb{R}^3$ 分别对应速度、姿态、加速度偏置以及角速度偏置的高斯随机脉冲噪声, 其对应的协方差矩阵定义如下:

$$\begin{aligned}
\mathbf{w}_v &= \sigma_{a_n}^2 \Delta t^2 \mathbf{I} \begin{bmatrix} m^2 \\ s^2 \end{bmatrix} \\
\mathbf{w}_\theta &= \sigma_{\omega_n}^2 \Delta t^2 \mathbf{I} \begin{bmatrix} rad^2 \end{bmatrix} \\
\mathbf{w}_a &= \sigma_{a_\omega}^2 \Delta t^2 \mathbf{I} \begin{bmatrix} m^2 \\ s^4 \end{bmatrix} \\
\mathbf{w}_\omega &= \sigma_{\omega_\omega}^2 \Delta t^2 \mathbf{I} \begin{bmatrix} rad^2 \\ s^2 \end{bmatrix}
\end{aligned} \tag{6}$$

其中 $\sigma_{a_n}^2$, $\sigma_{\omega_n}^2$, $\sigma_{a_\omega}^2$, $\sigma_{\omega_\omega}^2 \in \mathbb{R}$ 分别表示加速度、角速度、加速度偏置和角速度偏置的高斯白噪声的方差。

1.3 ESKF 的预测与更新过程

误差状态卡尔曼滤波的核心思想是: 1) 将系统状态分别定义为真实状态和标称状态, 误差状态定义为两个状态的差值; 2) 将标称状态作为较大的状态量, 其继承系统的非线性; 3) 将线性度高的误差状态作为小的状态量进行预测与估计。总的来说, 标称状态不考虑 IMU 的测量噪声以及扰动信息, 而误差状态包含这些扰动, 标称状态的地推与误差状态的预测同时进行更新, 然后通过 GPS 信号去修正误差状态的估计, 进而将误差状态融合到标称状态中去, 最后误差状态及其协方差矩阵复位, 如此循环往复。ESKF 同过推到误差状态动力学方程, 借助非线性模型的摄动, 来实现误差状态及其协方差的最优预测与更新。因为误差状态动力学的非线性程度更低, 所以与针对状态进行局部线性化的 EKF 相比, ESKF 局部线性化的模型误差更小, 进而提高了估计的精度。使用 ESKF 进行 GPS/IMU 融合的具体步骤框图可见图 1。

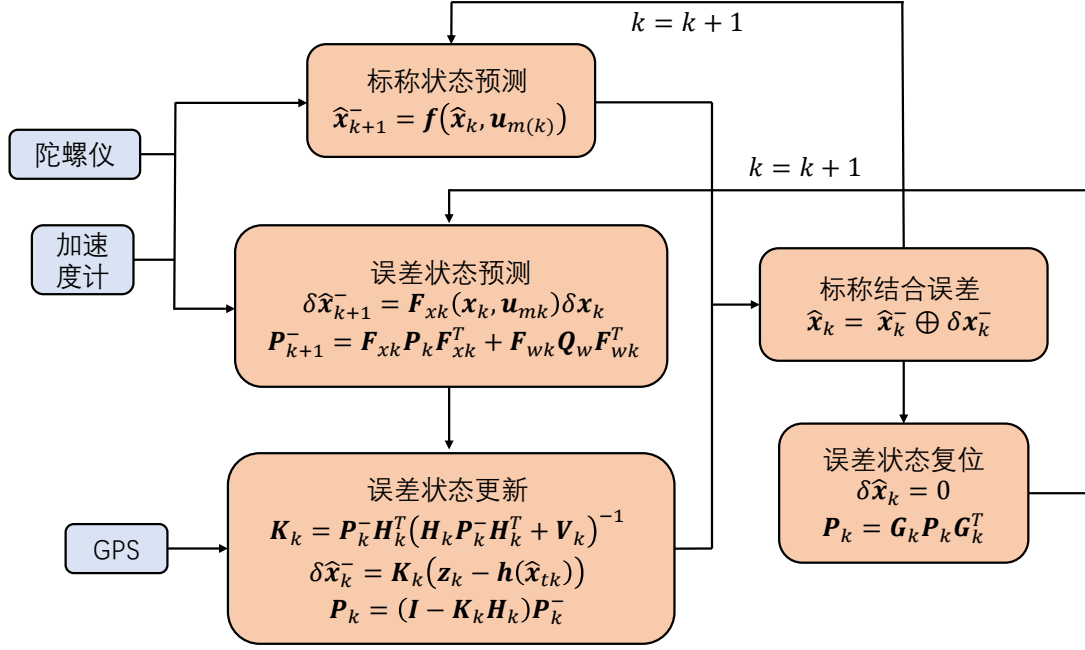


图 1 基于 EKSF 的 GPS/IMU 融合流程图

1.3.1 全状态的更新过程

定义全状态、误差状态、IMU 测量以及噪声的向量形式如下：

$$\mathbf{x}_k = \begin{bmatrix} \mathbf{p}_k \\ \mathbf{v}_k \\ \mathbf{q}_k \\ \mathbf{a}_{bk} \\ \boldsymbol{\omega}_{bk} \end{bmatrix}, \quad \delta \mathbf{x}_k = \begin{bmatrix} \delta \mathbf{p}_k \\ \delta \mathbf{v}_k \\ \delta \mathbf{q}_k \\ \delta \mathbf{a}_{bk} \\ \delta \boldsymbol{\omega}_{bk} \end{bmatrix}, \quad \mathbf{u}_{mk} = \begin{bmatrix} \mathbf{a}_{mk} \\ \boldsymbol{\omega}_{mk} \end{bmatrix}, \quad \mathbf{w}_k = \begin{bmatrix} \mathbf{w}_{vk} \\ \mathbf{w}_{\theta k} \\ \mathbf{w}_{ak} \\ \mathbf{w}_{\omega k} \end{bmatrix} \quad (7)$$

结合式 (3) 和式 (7)，可以得到标称状态递推方程：

$$\mathbf{x}_{k+1} = \mathbf{f}(\mathbf{x}_k, \mathbf{u}_{mk}) \quad (8)$$

其中 \mathbf{f} 状态变量的递推函数，结合式 (5)，可得误差状态递推方程：

$$\begin{aligned} \delta \mathbf{x}_{k+1} &= \mathbf{f}_\delta(\mathbf{x}_k, \delta \mathbf{x}_k, \mathbf{u}_{mk}, \mathbf{w}_k) \\ &= \mathbf{F}_{xk}(\mathbf{x}_k, \mathbf{u}_{mk})\delta \mathbf{x}_k + \mathbf{F}_{wk}\mathbf{w}_k \end{aligned} \quad (9)$$

其中 \mathbf{f}_δ 表示误差状态的递推函数， \mathbf{F}_{xk} 和 \mathbf{F}_{wk} 分别为误差状态和噪声状态对应的雅可比矩阵，本文直接使用了文[4]的推导结果来获得雅可比矩阵：

$$\mathbf{F}_{xk} = \begin{bmatrix} \mathbf{I} & \mathbf{I}\Delta t & 0 & 0 & 0 \\ 0 & \mathbf{I} & -\mathbf{R}_k\mathbf{L}_{sk}(\mathbf{a}_{mk} - \mathbf{a}_{bk})\Delta t & -\mathbf{R}_k\Delta t & 0 \\ 0 & 0 & \mathbf{R}_k^T(\boldsymbol{\omega}_{mk} - \boldsymbol{\omega}_{bk})\Delta t & 0 & -\mathbf{I}\Delta t \\ 0 & 0 & 0 & \mathbf{I} & 0 \\ 0 & 0 & 0 & 0 & \mathbf{I} \end{bmatrix} \quad (10)$$

$$\mathbf{F}_{wk} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ \mathbf{I} & 0 & 0 & 0 \\ 0 & \mathbf{I} & 0 & 0 \\ 0 & 0 & \mathbf{I} & 0 \\ 0 & 0 & 0 & \mathbf{I} \end{bmatrix} \quad (11)$$

1.3.2 ESKF 的预测过程

基于式 (9)，可以得到误差状态以及协方差预测方程：

$$\begin{aligned}\delta\hat{\mathbf{x}}_{k+1}^- &= \mathbf{F}_{xk}(\mathbf{x}_k, \mathbf{u}_{mk})\delta\mathbf{x}_k \\ \mathbf{P}_{k+1}^- &= \mathbf{F}_{xk}\mathbf{P}_k\mathbf{F}_{xk}^T + \mathbf{F}_{wk}\mathbf{Q}_w\mathbf{F}_{wk}^T\end{aligned}\quad (10)$$

其中 \mathbf{Q}_w 为噪声矩阵，其具体形式为：

$$\mathbf{Q}_w = \begin{bmatrix} \mathbf{W}_v & 0 & 0 & 0 \\ 0 & \mathbf{W}_\Theta & 0 & 0 \\ 0 & 0 & \mathbf{W}_A & 0 \\ 0 & 0 & 0 & \mathbf{W}_\Omega \end{bmatrix}\quad (11)$$

1.3.2 ESKF 的观测过程

由于加速度计以及陀螺仪存在偏置，单纯地进行 IMU 积分估计会导致估计地位姿产生漂移，因此，本文使用 GPS 提供位置量测信息。一般的 GPS 提供的数据为 WGS84 坐标系下的经纬度信息，而本文定义的状态实在 ENU 坐标系下的，为此，需要使用文[2]中的坐标变换方法，将 GPS 数据转换至 ENU 笛卡尔坐标系，表示为 ${}^G\mathbf{p}_{Gps}$ 。这样就可以获得观测方程：

$${}^G\mathbf{p}_{Gps} = {}^G\mathbf{p} + {}^G\mathbf{R}^I\mathbf{p}_{Gps}\quad (11)$$

可以计算其对于误差状态的雅可比矩阵：

$$\begin{aligned}H &= \frac{\partial({}^G\mathbf{p} + {}^G\mathbf{R}^I\mathbf{p}_{Gps})}{\partial\delta\mathbf{x}} = \frac{\partial({}^G\mathbf{R}(1 + [\delta\boldsymbol{\theta}]_\times)^I\mathbf{p}_{Gps})}{\partial\delta\mathbf{x}} \\ &= [\mathbf{I} \quad \mathbf{0} \quad -{}^G\mathbf{R}[\cdot]^I\mathbf{p}_{Gps}]_\times \quad \mathbf{0} \quad \mathbf{0}\end{aligned}\quad (12)$$

至此，已经给出了 ESKF 预测更新的所有步骤。

2 GPS/IMU 融合实验

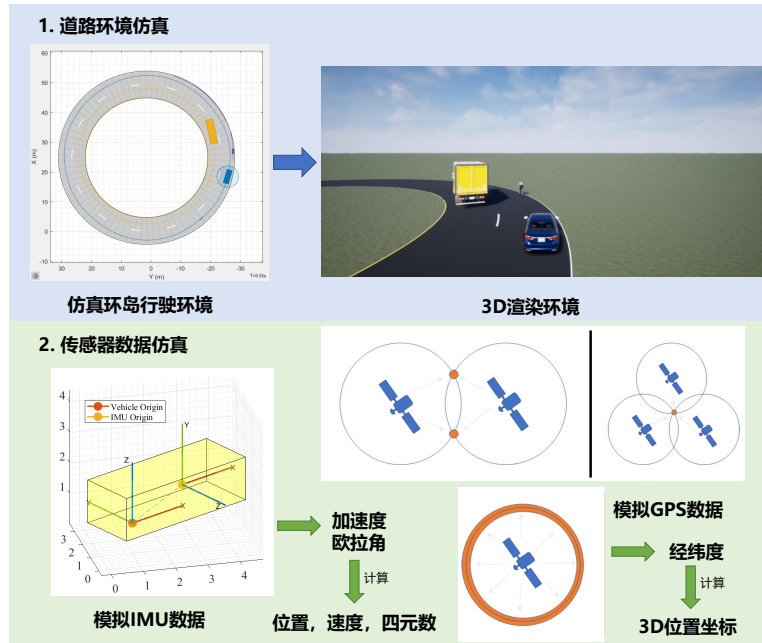


图2 仿真环境搭建与传感器数据模拟

基于 Matlab 仿真环境，本文设计了小车环岛定位跟踪实验，对 IMU/GPS 异步融合的算法效果进行分析，其中包括仿真环境搭建的示意图可见图 2。

分别对仅使用 IMU、仅使用 GPS 和基于 ESKF 融合 IMU/GPS 三种情况进行了分实验，最终结果如图 3 所示，其中 IMU 的加速度计和陀螺仪的采样频率均为 100Hz，加速度计的测量范围为 $\pm 19.6m/s^2$ ，噪声密度为 $0.01(m/s^2)/Hz^{\frac{1}{2}}$ ，陀螺仪的测量范围 $250rad/s$ ，噪声密度为 $0.0573(rad/s)/Hz^{\frac{1}{2}}$ ，磁力计的采样频率为 50Hz，GPS 的采样频率为 5Hz，小车的运动速度为 10m/s，环岛半径为 15m。

可以看到，仅用 IMU 或 GPS 都不能得到很好的定位效果，其中，由于 IMU 的漂移问题随着积分产生累计，IMU 在产生的误差会越来越大。而仅用 GPS 的情况下，由于 GPS 的采样频率较小，无法满足实时精准定位的要求，经过对比，使用 ESKF 算法融合 GPS 和 IMU 的效果较好，可见图 3。

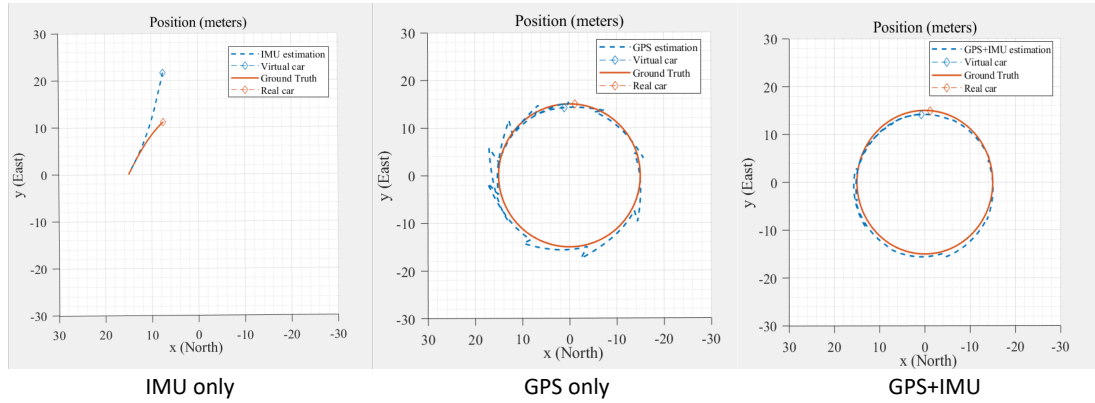


图 3 对比结果图

由图 4 所示，基于本文算法的融合策略在 x, y 轴上的误差变化在 $\pm 2m$ 内变化， z 轴上的误差在 $\pm 0.5m$ 的区间内，这是由于仿真过程中，传感器数据读取设置的测量噪声以及 IMU 动力学模型设置的噪声以及偏置造成的。




图 4 GPS/IMU 融合误差变化图

3 视觉惯导融合

上文中介绍了 GPS/IMU 的融合方案，但是在实际应用中，存在无信号的情况，第 2 节的实验也表明，当 GPS 信号弱时，IMU 无法很好的完成定位的任务。可以发现，IMU 能够高频输出姿态估计值，但由于在计算速度和位置时对测量结果进行了积分，使得误差放大导致较大的漂移。另外，单目相机能够低频返回准确的姿态估计，但会导致尺度模糊。这两者均不容易受地理位置的影响，因此在本节中，主要介绍将基于单目相机的视觉里程计的位姿估计与 IMU 的姿态估计相融合的松耦合 ESKF 方案。其中，IMU 的建模与第 1 节介绍的相同，因此，本节基于文[5]对视觉里程计的建模进行分析。

3.1 视觉里程计模型

视觉里程计（VO）根据相邻图像间特征点的变化来确定相机的位姿，并实现定位，与基于 IMU 和 GPS 的位姿估计相比，其相对稳定且价格便宜。但是，VO 的内在问题在于其在远距离定位导航中的漂移，因为 VO 的位姿估计基于相对测量（前后两帧图像），这导致误差累计并随着时间的增加趋于无穷。以基于特征匹配的方法为例，特征提取和三角化测量过程中均存在误差，经过长时间导航后，误差累积，测量值逐渐偏离真值。

考虑一般的相机模型，若 E 是世界坐标系到相机坐标系的变换矩阵， M 是 t 时刻到 $t + 1$ 时刻的变换矩阵。由于方向偏移限制在 $[-\pi, \pi]$ ，且其最终也导致位置的变换，因此下文中只考虑位置的漂移。容易得到：

$$E_{t+1} = E_t \cdot M_t \quad (13)$$

其中右乘 M_t 是因为 M_t 是 t 时刻相对相机坐标系的运动， E 和 M 的一般表示为：

$$\begin{bmatrix} R_{3 \times 3} & T_{3 \times 1} \\ 0_{1 \times 3} & 1 \end{bmatrix}_{4 \times 4} \quad (14)$$

其中 $R_{3 \times 3}$ 为旋转矩阵， $T_{3 \times 1}$ 为平移向量，其意味着使用旋转和平移来表示位姿的变换。对于平移漂移，有：

$$\Delta d_{t+1} = \|d_{t+1} - \bar{d}_{t+1}\| \quad (15)$$

其中 $\|\cdot\|$ 是欧几里得距离， d_{t+1} 和 \bar{d}_{t+1} 分别表示 $t + 1$ 时刻的位姿估计值和真值。

3.1.1 漂移模型

式（15）中的漂移是非平稳过程，并且会随时间趋于无穷，其漂移模型为：

$$\ln \Delta d_t = F_t \cdot \mathbf{p} + u_t \quad (16)$$

其中 $F_t = [1, \ln d_t]$ 是一个无界的确定性矩阵， $\mathbf{p} = [a, b]^T$ 是一个待辨识的参数向量， u_t 是零均值的随机过程。简单的说，模型由确定性部分 $F_t \cdot \mathbf{p}$ 和随机部分 u_t 组成。另外，可以发现，如果不考虑 u_t ，则有 $\Delta d_t = e^a \cdot d_t^b$ ，这说明漂移随着距离呈指数增长，并且是无界的，这与我们的先验知识是一致的。

3.1.1 参数辨识

漂移模型中的参数辨识，基于最小二乘法，采集大量的测量数据，之后可以分为两个步骤：1. 假设 $u_t = 0$ ，估计参数 \mathbf{p} ，并记为 $\bar{\mathbf{p}}$ 。2. 根据 $\bar{u}_t = \Delta d_t - F_t \cdot \bar{\mathbf{p}}$ ，估计 \bar{u}_t 。其中对于第一步，使用最小二乘法，容易得到：

$$\bar{\mathbf{p}}(N) = \left(\sum_{t=1}^N F_t^T F_t \right)^{-1} \cdot \sum_{t=1}^N F_t^T \Delta d_t \quad (17)$$

使用式（17）的结果，可以得到 \bar{u}_t ，然后使用一阶高斯-马尔科夫过程对齐进行建模，有：

$$\bar{u}_t = \left(1 - \frac{1}{\tau} \right) \bar{u}_{t-1} + \omega_n \quad (18)$$

其中 τ 成为相关时间， ω_n 为均值为零方差为 σ_n^2 的模型噪声。高斯-马尔科夫过程的过程方差 σ_u^2 为：

$$\sigma_u^2 = \frac{\sigma_n^2}{2/\tau + 1/\tau^2} \quad (19)$$

实际推导过程中，由于 F_t 是一个无界矩阵，因此需要对模型的收敛性进行分析，具体过程可见文[5]，限于篇幅，本文只是利用了其中的结果，对推导不做说明。至此，即可对相机的测量位姿进行计算，即为：

$$\mathbf{p}_{vk} = s \cdot \mathbf{p}_k + \bar{u}_t \quad (20)$$

其中 s 为相机的尺度因子， \mathbf{p}_{vk} 即为相机的位姿测量，与第2节中相同，将式（20）写作测量方程，可以用 ESKF 来对惯导和视觉里程计进行融合

4 VIO 融合实验

基于 Matlab Driving Scenario Designer Tools 搭建仿真场景，为了验证长时间导航的准确性，设置仿真时间为 80s，仿真路径长且设置弯道，将道路轨迹设为真值，其具体场景可见图 5 所示：




图 5 城市道路仿真场景

设置 VO 的采样频率为 4Hz, 位置和角度的测量噪声方差均为 0.1, 尺度因子设为 2, τ 为 200。IMU 和小车的设置与第 3 节中相同, 为了分析 VIO 导航的效果, 对 VO 定位与 VIO 融合导航的结果进行比较, 具体结果可见图 6。

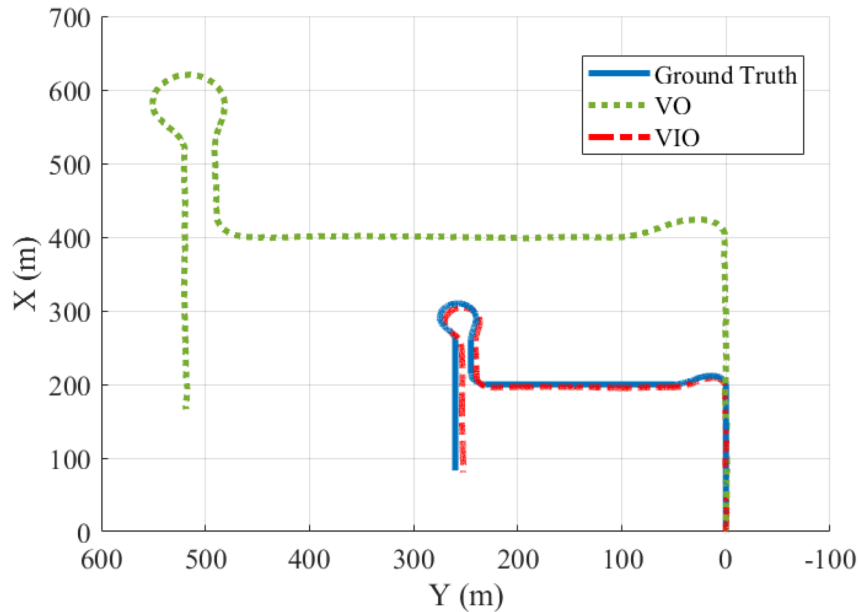


图 6 VIO 定位导航结果

可见, VO 在估计轨迹形状方面相对准确, 而 VIO 融合的结果一定程度上减小了 VO 测量值中比例因子不确定性带来的影响以及 IMU 积分带来的偏移。

5 讨论

本文讨论了在 GPS 信号弱和 GPS 信号丢失场景下, 基于 ESKF 对 GPS/IMU 信号和 IMU/VO 进行融合的方案, 并通过仿真实验验证。需要注意的是, 本文讨论的方法是在 EKF 框架上给出的松耦合方案, 与紧耦合方案相比, 例如文[6]提出的 MSCKF, 准确度较低, 但处理量少, 速度快。接下来的工作将对基于滤波以及优化的紧耦合方案进行研究。

参考文献

- [1] 高翔, 张涛, 刘毅, 颜沁睿. 视觉 SLAM 十四讲: 从理论到实践. 北京: 电子工业出版社, 2019.
- [2] 罗建军, 马卫华, 袁建平, 岳晓奎. 组合导航原理与应用. 西安: 西北工业大学出版社, 2012. (第四章)
- [3] Sola. J. "Quaternion Kinematics for the Error-State Kalman Filter." ArXiv e-prints, arXiv:1711.02508v1, 2017.
- [4] Sola. J, Deray. J, Atchuthan. D. "A micro Lie theory for state estimation in robotics." arXiv:1812.01537, 2018.
- [5] R. Jiang, R., R. Klette, and S. Wang. "Modeling of Unbounded Long-Range Drift in Visual Odometry." 2010 Fourth Pacific-Rim Symposium on Image and Video Technology. Nov. 2010, pp. 121-126.
- [6] A. I. Mourikis and S. I. Roumeliotis, "A multi-state constraint Kalman filter for vision-aided inertial navigation," IEEE International Conference on Robotics and Automation, 2007, no. April, pp. 3565-3572.